

Ανάκτηση Πληροφορίας Project 2023

Ρωμανός Κώτσης AM 4714

GitHub repository : <https://github.com/ely2D/Information-Retrival>

Σύντομη περιγραφή εφαρμογής

Η εφαρμόγηση λειτουργεί για αρχεία csv με δομή: Artist,Title,Album,Year,Date,Lyric. Έτσι, πριν την έναρξη της εφαρμογής, δώστε ένα κατάλληλο αρχείο στον κώδικα της searchEngine. Στο παράθυρο όπου θα εμφανιστεί, επιλέξτε σε ποιο πεδίο να γίνει αναζήτηση από το drop-down menu "Search By" και πληκτρολογήστε μία λέξη key-word και πατήστε το κουμπί "Search". Μετά την αναζήτηση, θα εμφανιστεί ένα καινούργιο παράθυρο "searchResults" με τα 10 πρώτα αποτελέσματα της αναζήτησης. Πατώντας το κουμπί "Load 10 More" εμφανίζονται τα επόμενα 10 αποτελέσματα. Επιπρόσθετα, δίνεται ομαδοποίησης των αποτελεσμάτων ανά καλλιτέχνη. Έτσι διαλέγοντας την επιλογή "Artist" από το drop-down menu "Group by" εμφανίζεται ένα καινούργιο παράθυρο με όλα τα αποτελέσματα από κάθε καλλιτέχνη.

Εισαγωγή

Το σύστημα αποσκοπεί στην δημιουργία μίας εφαρμόγησης αναζήτησης πληροφοριών για καλλιτέχνες και τραγούδια, η οποία δίνει την δυνατότητα στον χρήστη να δώσει λέξεις κλειδιά και να επιλέξει που να ψάξει και το σύστημα να του επιστρέψει πληροφορίες για τα τραγούδια όπου πληρούν τις προϋποθέσεις που έδωσε ο χρήστης. Ως προς την λειτουργικότητα το σύστημα υλοποιεί τις εξής αναζητήσεις:

- Όνομα Καλλιτέχνη
- Τίτλο τραγουδιού
- Τίτλο άλμπουμ
- Έτος κυκλοφορίας
- Ημερομηνία κυκλοφορίας
- Στίχοι τραγουδιού

Συλλογή

Η Συλλογή όπου έχει χρησιμοποιηθεί, όπου πάνω στην οποία έχει υλοποιηθεί το σύστημα, είναι ένα από τα site που έχουν παρασχεθεί στις διαφάνεις, το "Kaggle". Συγκεκριμένα είναι μία συλλογή από csv αρχεία με δομή πεδίων "Artist,Title,Album,Year,Date,Lyric" και κάθε αρχείο περιέχει πληροφορίες για ένα καλλιτέχνη. Έχει δημιουργηθεί κι ένα αρχείο csv "various_artists" όπου περιέχει πληροφορίες από διάφορους καλλιτέχνες.

Ανάλυση κειμένου και κατασκευή ευρετηρίου

Για την ανάλυση κειμένου έγινε χρήση standardAnalyzer. Αυτό διότι ο συγκεκριμένος τρόπος ανάλυσης παίρνει κάθε token κι το κάνει lowercase για την καλύτερη αναζήτηση. Επίσης, απαλοίζει stop words και τυχόν τονισμούς. Αφού έχουμε συλλέξει τα άρθρα τα κάνουμε tokenize, δηλαδή τα διαιρούμε σε γλωσσικά σύμβολα. Έπειτα, προεπεξεργαζόμαστε γλωσσολογικά τα σύμβολα και ευρετηριάζουμε τα έγγραφα στα οποία περιλαμβάνεται κάθε όρος. Τα πεδία του κάθε εγγράφου είναι ο Καλλιτέχνης, ο

Ανάκτηση Πληροφορίας Project 2023

Τίτλος του τραγουδιού, το Άλμπουμ στο οποίο υπάρχει το τραγούδι, η Χρονία μέσα στην οποία δημοσιεύτηκε, η Ημερομηνία όπου δημοσιεύτηκε και οι Στίχοι του τραγουδιού. Αντιστοίχως δημιουργήθηκαν ανάλογα ευρετήρια τύπου TextField για κάθε πεδίο, έτσι ώστε να μπορεί να γίνει αναζήτηση σε συγκεκριμένα πεδία.

Αναζήτηση

Ο χρήστης δίνει λέξεις-κλειδιά και γίνεται αναζήτηση στην συλλογή για τα έγγραφα όπου περιέχουν τις λέξεις αυτές σε όλα τα πεδία, εφόσον έχει επιλέξει αναζήτηση σε όλα τα πεδία. Επιπρόσθετα δίνεται η επιλογή για αναζήτηση όρων σε συγκεκριμένα πεδία, πχ Όνομα Καλλιτέχνη, Τίτλο τραγουδιού, Στίχοι κτλ.

Παρουσίαση Αποτελεσμάτων

Το σύστημα παρουσιάζει τα αποτελέσματα με βάση την συνάφεια τους, δηλαδή το πόσο 'καλά' ανταποκρίνονται στις ανάγκες του χρήστη. Επίσης τα αποτελέσματα εμφανίζονται ανά 10 και ο χρήστης μπορεί να προχωρήσει στα επόμενα 10(εάν αυτά υπάρχουν), με τις λέξεις-κλειδιά να είναι highlighted για την εύκολη ανάγνωσή τους. Τέλος υπάρχει λειτουργία ομαδοποιήσεις των αποτελεσμάτων με κριτήριο τον καλλιτέχνη.

Interface

Το interface υλοποιημένο σε 2 κλάσης, GUI και searchResults. Συγκεκριμένα η GUI, κατά την έναρξη δημιουργεί ένα καινούργιο παράθυρο το οποίο περιέχει ένα Menu-Bar για την επιλογή πεδίου αναζήτησης, ένα searchField για την πληκτρολόγηση της λέξης-κλειδί και ένα Button για την έναρξη της αναζήτησης στο αρχείο για τα έγγραφα όπου πληρούν τις προϋποθέσεις αναζήτησης. Έπειτα, κλείνει το παράθυρο και καλεί την searchResults, η οποία δημιουργεί ένα νέο παράθυρο με τα αποτελέσματα. Αυτή είναι και όπου καλεί την μέθοδο searchEngine, για την εκτέλεση της αναζήτησης στο αρχείο και την επιστροφή των αποτελεσμάτων. Το παράθυρο αυτό περιέχει ένα Menu-Bar για την επιλογή ομαδοποίησης ανά Καλλιτέχνη, ένα Scroll όπου φιλοξενεί ένα Table για την παρουσίαση των αποτελεσμάτων και ένα Button για να εμφανιστούν τα επόμενα 10 αποτελέσματα. Επίσης εάν επιλεγθεί η ομαδοποίηση ανά καλλιτέχνη, δημιουργείτε ένα παράθυρο για κάθε καλλιτέχνη με πληροφορίες για τον καθένα όπου επιστράφηκαν από την αναζήτηση.

Παρατηρήσεις:

Το κομμάτι της ιστορίας αναζητήσεων και των εναλλακτικών ερωτημάτων με βάση αυτής, δυστυχώς δεν υλοποιήθηκε, καθώς το σύστημα δημιουργεί ένα καινούργιο index κάθε φορά που εκτελείτε η εφαρμογή και το αποθηκεύει σε directory στην μνήμη με ByteBufferDirectory. Έτσι δεν μπορεί να κρατηθεί ιστορικό πληροφορίας αναζήτησης για την πρόταση εναλλακτικών ερωτημάτων.